فاز اول - اجرای Depth Anything روی یک تصویر

در این فاز، یک تصویر RGB انتخاب شده و مدل Depth Anything برای تخمین عمق اجزای تصویر اجرا می‌شود.

فعالیت‌ها:

- بارگذاری تصویر را با OpenCV / Python یا PIL
- بارگذاری مدل Depth Anything
- تولید نقشه عمق (Depth Map) برای تصویر ورودی
- نمایش تصویر اصلی و نقشه عمق در کنار یکدیگر
- ذخیره نقشه عمق به‌صورت فایل تصویری

موارد مورد بررسی در گزارش:

- مدل چه چیزی را بعنوان ورودی دریافت می‌کند؟
- خروجی مدل چیست؟
- ابعاد خروجی با تصویر ورودی چه ارتباط دارد؟
- Depth Map چه اطلاعاتی در اختیار قرار می‌دهد؟

گزارش اجرای Depth Anything V2

در این تمرین، مدل **Depth Anything V2 Small** برای تخمین عمق یک تصویر RGB از مجموعه‌داده **Depth8** استفاده شد. مجموعه‌داده Depth8 یک مجموعه کوچک شامل ۸ تصویر RGB-D از محیط‌های داخلی است که از مجموعه‌داده SUN RGB-D انتخاب شده است. این مجموعه بیشتر برای آزمایش و بررسی عملکرد کدها و مدل‌های تخمین عمق استفاده می‌شود و برای ارزیابی جامع مدل‌ها در مقیاس بزرگ طراحی نشده است.

در این تمرین تصویر image_01.png انتخاب و مدل Depth Anything V2 روی آن اجرا شد.

اجرای مدل و تولید Depth Map

تصویر ورودی با استفاده از کتابخانه PIL بارگذاری و به فرمت RGB تبدیل شد. سپس مدل از پیش آموزش‌دیده زیر با استفاده از کتابخانه Hugging Face Transformers بارگذاری شد:

depth-anything/Depth-Anything-V2-Small-hf

تصویر RGB پس از پیش‌پردازش به عنوان ورودی مدل استفاده شد و مدل یک نقشه عمق دوبعدی تولید کرد. سپس خروجی مدل به ابعاد تصویر اصلی تغییر اندازه داده شد و تصویر RGB و Depth Map در کنار یکدیگر نمایش داده شدند.

Depth Map همچنین به صورت فایل تصویری و آرایه NumPy ذخیره شد.

- ✓ ورودی مدل: این مدل یک تصویر RGB (H×W×3) دریافت می‌کند. سپس پردازشگر تصویر، تصویر ورودی را به تنسورهای نرمال‌سازی‌شده‌ای تبدیل می‌کند که برای مدل مبتنی بر ترنسفورمر مناسب هستند.

- ✓ خروجی مدل: مدل یک نقشه عمق (Depth Map) تولید می‌کند که در آن هر پیکسل حاوی یک مقدار عمق پیش‌بینی‌شده است.

- ✓ لازم به ذکر است خروجی مدل، **فاصله فیزیکی واقعی بر حسب متر نبوده** و **عمق نسبی (Relative Depth)** است.

- ✓ رابطه میان ابعاد خروجی و ورودی: نقشه عمق پس از تغییر اندازه (resize) با ابعاد مکانی تصویر RGB اصلی مطابقت دارد و هر مقدار عمق (depth value) متناظر با یک پیکسل در تصویر ورودی است[1].

- ✓ معنای نقشه عمق:
نقشه عمق، ترتیب نسبی (relative distance) فواصل اشیاء را نشان می‌دهد:
مقادیر کوچک‌تر یا بزرگ‌تر، بسته به قراردادِ بصری‌سازی، بیانگر نواحی نزدیک‌تر یا دورتر هستند.
اشیاء با عمق یکسان، معمولاً مقادیر عمق مشابهی دارند.

[1] مدل «Depth Anything» لزوماً با اندازه تصویر اصلی کار نمی‌کند. ابتدا تصویر ورودی توسط ماژول پیش‌پردازش تغییر اندازه می‌یابد تا با ابعاد ورودی مورد نیاز مدل مطابقت پیدا کند. سپس مدل، یک نقشه عمق با همان ابعاد مکانی ورودیی پردازش‌شده تولید می‌کند. در نهایت، نقشه عمق پیش‌بینی‌شده مجدداً به وضوح تصویر اصلی تغییر اندازه داده می‌شود تا بتوان آن را در کنار تصویر RGB نمایش داد یا به‌صورت پیکسل‌به‌پیکسل با نقشه عمق مرجع (Ground-truth) مقایسه کرد.

فاز دوم – تحلیل عددی Depth Map

در این فاز، ویژگی‌های عددی نقشه عمق تولیدشده در فاز قبل بررسی می‌شود:

```
depth.shape

depth.dtype

depth.min()

depth.max()

depth.mean()

depth.std()
```

- شناسایی مختصات پیکسلی دارای کمترین و بیشترین مقدار عمق
- محاسبه مقدار عمق در مرکز تصویر
- رسم هیستوگرام توزیع مقادیر عمق
- تبدیل نقشه عمق به آرایه NumPy و ذخیره آن

سوال تحلیلی:

آیا می‌توان گفت مقدار depth = 0.25 یعنی شئ دقیقا ۲۵ سانتی‌متر با دوربین فاصله دارد؟ پاسخ باید با استدلال فنی و با بررسی تفاوت میان Relative Depth و Metric Depth ارائه شود.

تحلیل عددی نقشه عمق پیش‌بینی‌شده:

Parameter	Value
Shape	(427, 561)
Data type	float32
Minimum depth	0.1424
Maximum depth	6.5203
Mean depth	3.1419
Standard deviation	1.3730

نقشه عمق خروجی دارای همان ابعاد مکانی تصویر ورودی است. این بدان معناست که هر پیکسل در تصویر RGB، یک مقدار عمق پیش‌بینی‌شده‌ی متناظر دارد.

- مختصات pixel با کمترین مقدار depth :

$D_{min}=0.1424$

در مختصات پیکسل:

(row,column)=(234,542)

حداقل مقدار پیش‌بینی‌شده مربوط به کمترین خروجی مدل است. از آنجایی که مدل‌های تخمین عمق تک‌چشمی اغلب عمق **معکوس نسبی** (اختلاف) را پیش‌بینی می‌کنند، **مقادیر کوچکتر عموماً مناطق دورتر** را نشان می‌دهند، در حالی که مقادیر بزرگتر مناطق نزدیکتر را نشان می‌دهند.

این مدل، بازنمایی‌ای مرتبط با عمق معکوس نسبی را پیش‌بینی می‌کند:

$$D_{inv} \propto \frac{1}{Z}$$

D_{inv} = معکوسِ عمقِ پیش‌بینی‌شده
Z = فاصلهٔ واقعی از دوربین

- مختصات pixel با بیشترین مقدار depth :

$D_{max}=6.520$

در مختصات:

(row,column)=(267,0)

این ناحیه در مقایسه با سایر پیکسل‌ها، نسبتاً نزدیکتر تخمین زده می‌شود.

- عمق پیکسل مرکزی:
- مرکز تصویر عبارت است از:

(row,column)=(213,280)

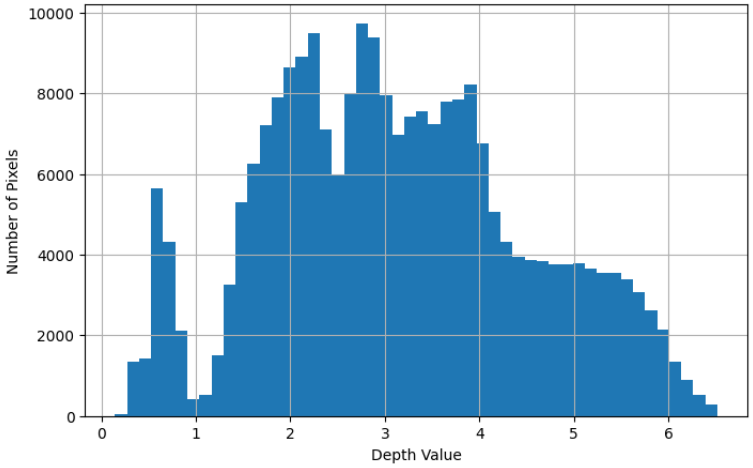
مقدار عمق پیش‌بینی‌شده در این موقعیت برابر است با:

$D_{center}=4.1182$

این مقدار نشان‌دهنده سطح عمق نسبی ناحیه مرکزی تصویر است.

- هیستوگرام مقادیر عمق

نمودار ۱- هیستوگرام عمق



محور X: مقدار عمق (۰/۱۴ - ۶/۵۲)

این‌ها مقادیر خروجی مدل هستند، نه واحد متر.
برای مدل Depth Anything V2:

- مقادیر کمتر ← معمولاً نواحی دورتر (تفسیر به عنوان «عمق معکوس»)
- مقادیر بیشتر ← معمولاً نواحی نزدیک‌تر

محور Y: تعداد پیکسل‌ها
محور عمودی نشان‌دهنده تعداد پیکسل‌هایی است که مقدار عمق مشخصی دارند.
برای مثال، اگر هیستوگرام دارای قله‌ای بزرگ باشد این به معنی آنست که بخش بزرگی از پیکسل‌های تصویر، عمق نسبی پیش‌بینی‌شده‌ی مشابهی در آن حدود دارند.
این وضعیت اغلب با یک *پس‌زمینه غالب* یا *سطحی وسیع در صحنه* مطابقت دارد.

- تفسیر میانگین و انحراف معیار

میانگین: 3.14

نشان‌دهنده آن است که متوسط مقدار عمق پیش‌بینی‌شده در سراسر تصویر، حدود ۳٫۱۴ است.

انحراف معیار: 1.37

در مقایسه با میانگین، نسبتاً بزرگ است : $\frac{1.37}{3.14} \approx 0.44$

این امر نشان می‌دهد که مقادیر عمق در بازه‌ای وسیع پراکنده شده‌اند؛ بدین معنا که تصویر شامل نواحی‌ای با فواصل نسبیی متفاوت است.

هیستوگرام دو قله دارد و نشان از جدایش میان اشیاء پیش‌زمینه و نواحی پس‌زمینه است.

سوال تحلیلی:

خیر، نمی‌توان گفت مقدار depth = 0.25 یعنی شئ دقیقا ۲۵ سانتی‌متر با دوربین فاصله دارد.

دلیل آن این است که مدل « Depth Anything V2 » عمق نسبی (Relative Depth) را پیش‌بینی می‌کند، عمق متریک (Metric Depth) را نمی‌دهد.

عمق نسبی تنها ترتیب قرارگیری پیکسل‌ها نسبت به یکدیگر را مشخص می‌کند:

مثال:

عمق شیء الف = 0.20 و عمق شیء ب = 0.60

این مقادیر نشان می‌دهند که یک شیء نسبت به دیگری نزدیک‌تر یا دورتر است، اما به معنای ۰٫۲۰ متر و ۰٫۶۰ متر نبوده و مقادیر فواصل فیزیکی کالیبره‌شده نیستند.

در مقابل، مدل‌های عمق متریک با استفاده از اندازه‌گیری‌های واقعی عمق آموزش می‌بینند و می‌توانند مقادیری مانند ۱٫۲۵ متر و ۳٫۴۰ متررا خروجی دهند.

بنابراین عمق ۰٫۲۵ ≠ ۲۵ سانتی‌متر مگر اینکه مدل به‌طور خاص با استفاده از پارامترهای دوربین و داده‌های مرجع (Ground Truth) عمق متریک کالیبره شده باشد.

فاز سوم – مقایسه مدل‌ها و Trade-off

در این فاز، حداقل دو نسخه متفاوت از مدل Depth Anything انتخاب شده و عملکرد آن‌ها از نظر کیفیت تخمین عمق، سرعت و مصرف منابع محاسباتی مقایسه می‌شود.

برای هر مدل روی حداقل ۱۰ تصویر inference انجام گردد.

اندازه‌گیری و مقایسه معیارهای زیر:

Model	Input Size	Average Inference Time	FPS	Memory	Quality
Model A					
Model B					

نکته:

زمان preprocessing و postprocessing را در صورت امکان جداگانه بررسی کنید.

سوال:

فرض کنید یک سیستم باید با حداقل 20 FPS کار کند. کدام مدل را انتخاب می‌کنید؟ انتخاب خود را با توجه به سرعت، حافظه، کیفیت و سخت‌افزار توجیه کنید.

مقایسه مدل‌های Depth Anything V2 و تحلیل Trade-off

در این تمرین دو نسخه از مدل Depth Anything V2 شامل:

- Depth Anything V2 Small
- Depth Anything V2 Base

روی مجموعه‌داده **Depth8** ارزیابی شدند. از آنجا که این مجموعه‌داده شامل تنها ۸ تصویر RGB-D است، تمام ۸ تصویر برای مقایسه استفاده شدند.

هدف، بررسی تعادل بین **کیفیت تخمین عمق، سرعت پردازش، مصرف حافظه و امکان استفاده در سیستم‌های Real-time** بود.

روش ارزیابی

از آنجا که Depth Anything V2 خروجی **Relative Depth** تولید می‌کند و Ground Truth مجموعه Depth8 دارای **Metric Depth** است، ابتدا خروجی مدل با استفاده از تبدیل Scale و Shift با عمق واقعی هم‌مقیاس شد:

$$D_{aligned} = aD_{pred} + b$$

سپس معیارهای MAE، RMSE و AbsRel محاسبه شدند.

نتایج مقایسه

Depth Anything V2 Base	Depth Anything V2 Small	معیار
0.0985	0.1042	MAE (m)
0.1247	0.1311	RMSE (m)
0.0634	0.0672	AbsRel
125.80	78.58	زمان(ms) Inference
185.70	141.08	زمان کل پردازش(ms)
5.91	7.51	FPS
628.7	257.4	حافظه(MB) GPU

تحلیل کیفیت

دقت مدل **Depth Anything V2 Base** کمی بهتر از نسخه Small است.

مقدار AbsRel از 0.06720.0672 به 0.06340.0634 کاهش یافته است که نشان‌دهنده بهبود جزئی در تخمین عمق است.

با این حال، این بهبود با افزایش قابل توجه هزینه محاسباتی همراه است.

تحلیل سرعت و حافظه

بیشترین تفاوت دو مدل مربوط به زمان Inference است:

- Small حدود **78.6 ms**
- Base حدود **125.8 ms**

همچنین مدل Base تقریباً ۲٫۴ برابر حافظه بیشتری مصرف می‌کند:

- Small: **257 MB**
- Base: **629 MB**

بنابراین مدل Base با وجود کیفیت بهتر، سرعت کمتر و هزینه محاسباتی بالاتری دارد.

بررسی شرط FPS۲۰

برای رسیدن به FPS۲۰ ، زمان پردازش هر تصویر باید کمتر از 50ms باشد.

$$FPS = \frac{1}{T_{total}}$$

$$T_{total} = T_{preprocessing} + T_{inference} + T_{postprocessing}$$

$T_{max} = 1 / 20 = 0.05s = 50ms$

نتایج:

مدل	FPS	دستیابی به FPS۲۰
Depth Anything V2 Small	7.51	خیر
Depth Anything V2 Base	5.91	خیر

بنابراین هیچ‌کدام از دو مدل روی سخت‌افزار آزمایش‌شده قادر به تأمین نیاز ۲۰ FPS نیستند.

انتخاب مدل

در صورت انتخاب بین این دو مدل، **Depth Anything V2 Small** گزینه مناسب‌تری است، زیرا:

- سرعت بالاتر دارد،
- حافظه کمتری مصرف می‌کند،
- با وجود کاهش جزئی کیفیت، عملکرد عمقی مشابهی ارائه می‌دهد.

اما برای یک سیستم واقعی با نیاز حداقل FPS۲۰ ، استفاده از مدل کوچک‌تر، کاهش رزولوشن ورودی، بهینه‌سازی یا سخت‌افزار قوی‌تر مورد نیاز است.

فاز چهارم – تخمین عمق روی ویدیو

در این فاز، مدل Depth Anything برای تخمین عمق فریم‌های یک ویدیو با مدت‌زمان حداقل ۳۰ ثانیه به کار گرفته می‌شود.

پیاده سازی Pipeline زیر:

1- Input video 2- read frame 3- depth Anything 4- Depth Map 5- Output Video

فعالیت‌ها:

- خواندن ویدیو به‌صورت فریم‌به‌فریم
- تولید نقشه عمق برای هر فریم
- ترکیب نقشه‌های عمق و تولید ویدیوی خروجی
- محاسبه نرخ فریم ویدیوی ورودی
- اندازه‌گیری نرخ واقعی پردازش مدل (Inference FPS)

برای این بخش، از دیتاست **TUM RGB-D** [۲] استفاده شده است. این دیتاست یکی از دیتاست‌های شناخته‌شده در حوزه بینایی ماشین و RGB-D است و شامل تصاویر RGB و داده‌های عمق از محیط‌های داخلی است. در این تمرین، توالی freiburg1_xyz به‌عنوان ویدئوی ورودی استفاده شد.

ویدئوی مورد استفاده شامل **798 فریم** با وضوح **640 × 480** و نرخ فریم ورودی **30 FPS** است. مدت زمان ویدئو حدود **26.6ثانیه** است.

روند پردازش به صورت زیر پیاده‌سازی شد:

Input Video → Read Frame → Depth Anything V2 → Depth Map → Output Video

هر فریم به‌صورت جداگانه با استفاده از OpenCV خوانده شد، از BGR به RGB تبدیل گردید و به مدل **Depth Anything V2 Small** داده شد. سپس نقشه عمق پیش‌بینی‌شده به اندازه اصلی تصویر بازگردانده و به‌صورت رنگی نمایش داده شد. در نهایت، نقشه‌های عمق به‌صورت فریم‌به‌فریم در یک ویدئوی خروجی ذخیره شدند.

نتایج عملکرد

معیار	مقدار
نرخ فریم ورودی	30 FPS
تعداد فریم‌ها	798
وضوح تصویر	640 × 480
مدت ویدئو	26.6ثانیه
مدل	Depth Anything V2 Small
میانگین زمانinference	60.01 ms/frame
نرخinference	16.66 FPS
زمان کلinference	47.89 s

[2] https://cvg.cit.tum.de/data/datasets/rgbd-dataset/download

زمان پردازش انتها به انتها	60.33 s
نرخ پردازش انتها به انتها (End-to-end)	13.23 FPS

نرخ **16.66 FPS** سرعت اجرای خود مدل را نشان می‌دهد، در حالی که نرخ **13.23 FPS** مربوط به کل فرایند پردازش شامل خواندن فریم، پیش‌پردازش، inference و پردازش نقشه عمق (depth resizing and depth visualization) است.

از آنجا که ویدئوی ورودی با نرخ **30 FPS** است، برای پردازش بلادرنگ (real-time) هر فریم باید در حداکثر حدود **33.3میلی‌ثانیه** پردازش شود. با توجه به زمان inference حدود **60.01 میلی‌ثانیه برای هر فریم**، مدل در سخت‌افزار مورد استفاده قادر به پردازش تمام فریم‌های ورودی با نرخ ۳۰ FPS نیست.

در انتها ویدئوی خروجی با موفقیت تولید و بررسی شد و برای تمام ۷۹۸ فریم، نقشه عمق تولید گردید.

فاز پنجم – Depth Visualization و Overlay

نقشه عمق خام را با استفاده از یک Color Map مناسب به تصویر رنگی تبدیل شوند.

سپس آن را با تصویر اصلی ترکیب گردند:

RGB Image + Colorized Depth →Depth Overlay

- پارامتر alpha را قابل تنظیم کنید.

خروجی: حداقل ۵ تصویر با alphaهای مختلف ارائه شوند.

سوال:

تغییر alpha چه تاثیری بر interpretability تصویر دارد؟

کدام مقدار را برای نمایش به کاربر انتخاب می‌کنید و چرا؟

در این بخش، فرآیند نمایش عمق و ترکیب تصویر RGB با نقشه عمق با استفاده از یک فریم از ویدئوی دیتاست **TUM RGB-D (توالی freiburg1_xyz)** پیاده‌سازی شد. سپس فریم RGB انتخاب‌شده با استفاده از مدل **Depth Anything V2 Small** پردازش و نقشه عمق مربوط به آن تولید گردید.

در ابتدا، نقشه عمق خام مدل با استفاده از یک **Color Map مناسب (PLASMA)** به یک تصویر رنگی تبدیل شد. سپس تصویر عمق رنگی با تصویر RGB اصلی ترکیب شد تا تصویر **Depth Overlay** ایجاد شود.

فرمول ترکیب تصاویر به صورت زیر استفاده شد:

$$\text{Overlay} = (1-\alpha) \times \text{RGB} + \alpha \times \text{Depth} + \gamma$$

در این فرمول، پارامتر **آلفا (alpha)** میزان تأثیر تصویر عمق در تصویر نهایی را کنترل می‌کند. همچنین گاما (γ) روشنایی اضافی به تصویر ترکیب‌شده می‌افزاید که در قسمت نیازی به آن نیست و مقدار آن ۰ خواهد بود.

برای بررسی اثر پارامتر آلفا، مقادیر مختلف زیرا برای آن در نظر گرفته شده و آزمایش و خروجی مربوط به هر مقدار تولید گردید.

$\alpha = 0.2, 0.4, 0.5, 0.7, 0.8$

تأثیر تغییر آلفا بر قابلیت تفسیر تصویر

مقدار آلفا تعیین می‌کند که تصویر RGB یا اطلاعات عمق در تصویر نهایی غالب باشد.

- در مقادیر پایین آلفا، تصویر اصلی RGB واضح‌تر باقی می‌ماند، اما اطلاعات عمق کمتر قابل مشاهده است.

- با افزایش آلفا، رنگ‌های مربوط به نقشه عمق غالب‌تر شده و تغییرات عمق بهتر دیده می‌شوند، اما جزئیات تصویر اصلی کاهش پیدا می‌کند.
- مقادیر متوسط آلفا باعث ایجاد تعادل بین اطلاعات ظاهری تصویر و اطلاعات عمق می‌شوند.

مقدار انتخابی برای نمایش به کاربر

یک نوار لغزنده (Slider) تعاملی برای تنظیم پویای میزان شفافیت نقشه عمق رنگی اضافه شد تا تأثیر آن بر قابلیت تفسیر تصویر ترکیبی RGB و نقشه عمق بررسی شود.

برای نمایش به کاربر، مقدار **alpha = 0.5** انتخاب شد، زیرا در این مقدار، تعادل مناسبی بین تصویر اصلی و نقشه عمق ایجاد می‌شود. در این حالت، جزئیات محیط همچنان قابل مشاهده هستند و همزمان تغییرات عمق نیز به‌خوبی نمایش داده می‌شوند.

این آزمایش نشان داد که تنظیم آلفا یک عامل مهم در کنترل خوانایی تصویر Overlay است و می‌توان با تغییر آن، میزان تأکید بر اطلاعات RGB یا عمق را متناسب با کاربرد مورد نظر تنظیم کرد.

- حائز ذکر است، اگر هدف، تشخیص و مقایسه اشیای نزدیک و دور باشد، بهتر است به‌جای ترکیب دو تصویر در قالب Overlay، تصویر اصلی و نقشه عمق رنگی در کنار یکدیگر نمایش داده شوند تا جزئیات تصویر اصلی حفظ شود و امکان مقایسه و تشخیص بهتر فاصله نسبی اشیا فراهم گردد.

فاز ششم – تشخیص اشیای نزدیک و دور

در این فاز، نقشه عمق برای بررسی و مقایسه فاصله نسبی اشیای مختلف در یک تصویر تحلیل می‌شود.

فعالیت‌ها:

- انتخاب تصویری شامل حداقل سه شیء در فاصله‌های متفاوت:

Object A: نزدیک , Object B:متوسط , Object C:دور

- تعیین یک کادر محدودکننده (Bounding Box) یا ناحیه موردنظر (ROI) برای هر شیء
- محاسبه میانگین عمق(Mean Depth) ، میانه عمق(Median Depth) ، حداقل عمق (Minimum Depth) و حداکثر عمق (Maximum Depth) برای هرROI
- ثبت و مقایسه نتایج در قالب جدول

Object	Mean	Median	Min	Max	Relative Distance
A					Near
B					Medium
C					Far

پرسش تحلیلی:

اگر مدل برای یک شیء مقدار depth برابر ۰,۲۱ و برای شیء دیگر ۰,۸۱ تولید کند، آیا می توان نتیجه گرفت که اولی مثلاً ۲ متر و دومی ۸ متر فاصله دارد؟ پاسخ باید فنی و مستدل باشد.

در این بخش، از **دیتاست Depth8** برای بررسی فاصله نسبی اشیاء در تصویر استفاده شد. تصویر انتخاب‌شده، image_08.png از دیتاست Depth8 بود که شامل اشیایی در فاصله‌های مختلف نسبت به دوربین است. تصویر RGB ورودی با استفاده از مدل **Depth Anything V2 Small** پردازش شد و نقشه عمق مربوط به آن تولید گردید.

برای تحلیل عمق، سه ناحیه مورد نظر (ROI) در تصویر بصورت دستی انتخاب شدند:

Object A (Near): شیء نزدیک به دوربین

Object B (Medium): شیء با فاصله متوسط

Object C (Far): شیء دورتر نسبت به دوربین

برای هرROI ، مقادیر آماری نقشه عمق محاسبه شدند که در جدول ذیل قابل مشاهده هستند:

Maximum Depth	Minimum Depth	Median Depth	Mean Depth	شیء
8.296	4.341	6.738	6.636	Object A (Near)
2.809	0.886	2.549	2.328	Object B (Medium)
2.989	0.472	1.521	1.340	Object C (Far)

نتایج نشان می‌دهد که مدل Depth Anything V2 توانسته است ترتیب فاصله نسبی اشیاء را به‌درستی تشخیص دهد. در این آزمایش، مقادیر بزرگ‌تر در خروجی مدل مربوط به اشیای نزدیک‌تر هستند و مقادیر کوچک‌تر به اشیای دورتر مربوط می‌شوند. بنابراین خروجی مدل رفتاری مشابه **Inverse Depth** دارد.

بررسی با Ground Truth دیتاست Depth8

از آنجا که دیتاست Depth8 دارای نقشه عمق واقعی (Metric Depth) است، همان ROI ها روی نقشه عمق Ground Truthنیز بررسی شدند. مقادیر Ground Truth بر حسب متر هستند و فاصله واقعی اشیاء از دوربین را نشان می‌دهند.

Maximum GT Depth (m)	Minimum GT Depth (m)	Median GT Depth (m)	Mean GT Depth (m)	شیء
1.049	0.561	0.755	0.751	Object A (Near)
2.319	1.236	1.393	1.473	Object B (Medium)
2.341	1.451	1.709	1.842	Object C (Far)

نتایج Ground Truth رابطه مورد انتظار را تأیید می‌کنند:

Object A < Object B < Object C

یعنی Object A نزدیک‌ترین و Object C دورترین شیء نسبت به دوربین است.

مقایسه نتایج نشان می‌دهد که Depth Anything V2 توانسته ترتیب نسبی فاصله‌ها را حفظ کند، اما مقادیر تولیدشده توسط مدل دارای واحد فیزیکی (مانند متر) نیستند.

تحلیل سؤال:

اگر مدل برای یک شیء مقدار depth برابر 0.21 و برای شیء دیگر مقدار 0.81 تولید کند، نمی‌توان نتیجه گرفت که فاصله این دو شیء به‌ترتیب ۲ متر و ۸ متر است.

دلیل این است که Depth Anything V2 مقدار Relative Depth بجای Metric Depth تولید می‌کند. مقادیر خروجی مدل فقط اطلاعات مربوط به ترتیب فاصله اشیاء را ارائه می‌دهند و نشان می‌دهند که کدام شیء نسبت به دیگری نزدیک‌تر یا دورتر است.

بنابراین Metric Depth ≠ Relative Depth است و برای تبدیل خروجی مدل به فاصله واقعی بر حسب متر، نیاز به مرحله کالیبراسیون با استفاده از داده‌های عمق واقعی یا اطلاعات دوربین وجود دارد.

تفاوت Mean و Median در تحلیل عمق

در محاسبه آمار هرROI ، دو معیار Mean و Median استفاده شدند:

Mean Depth: میانگین تمام مقادیر عمق پیکسل‌های داخل ROI است و نشان‌دهنده متوسط عمق ناحیه است.

Median Depth: مقدار میانی داده‌های مرتب‌شده است و نسبت به نقاط پرت (Outlier) و نویز کمتر حساس است.

در تحلیل عمق، Median معمولاً تخمین پایدارتری از عمق یک شیء ارائه می‌دهد، زیرا اثر پیکسل‌های مرزی یا نویزهای موجود در نقشه عمق را کاهش می‌دهد.

فاز هفتم – طراحی یک سیستم کاربردی مبتنی بر Depth Anything

در این فاز، یک سیستم کاربردی برای تشخیص نزدیک‌شدن اشیا به دوربین و هشداردهی هنگام ورود آن‌ها به محدوده خطر طراحی و پیاده‌سازی می‌شود.

Pipeline سیستم هشدار نزدیک شدن شیء:

1- Camera 2- Depth Anything 3- Depth Map 4- Nearest Object 5- Warning

اگر شیء وارد محدوده خطر شد، پیام زیر نمایش داده شود:

WARNING!

OBJECT TOO CLOSE

هدف این تمرین، طراحی و پیاده‌سازی یک سامانه هشدار نزدیکی مبتنی بر تخمین عمق تک‌چشمی با استفاده از مدل Depth Anything V2 است. سامانه با تولید نقشه عمق برای فریم‌های ویدئوی رانندگی، مقادیر عمق را در یک ناحیه مشخص از تصویر بررسی می‌کند و در صورت تشخیص محتوای نزدیک‌تر از آستانه تعیین‌شده، هشدار نمایش می‌دهد.

داده‌های مورد استفاده

در این آزمایش از ویدئوی رانندگی **Roadscapes، مربوط به توالی روز 11**[3] استفاده شده است. بازه زمانی ۶ تا ۵۰ ثانیه از ویدئوی اولیه استخراج شد که در نتیجه، یک ویدئوی ۴۴ ثانیه‌ای شامل ۱۳۲۰ فریم به دست آمد. وضوح تصویر برابر با ۱۲۸۰ × ۷۲۰ پیکسل و نرخ فریم ویدئو ۳۰ فریم بر ثانیه بود.

برای تخمین عمق از مدل **Depth Anything V2 Metric Small (ViT-S)** با وزن‌های آموزش‌دیده بر اساس مجموعه‌داده Virtual KITTI (VKITTI) استفاده شد. این مدل برای تولید نقشه عمق هر فریم به کار رفت. لازم به ذکر است که ویدئوی ورودی از مجموعه Roadscapes انتخاب شده است و نه از مجموعه Virtual KITTI ؛ نام VKITTI در اینجا به دامنه آموزش مدل عمق اشاره دارد.

روش پیاده‌سازی

۱- تخمین عمق

هر فریم ویدئو به مدل Depth Anything V2 داده شد و نقشه عمق متناظر با آن تولید گردید. خروجی مدل به‌صورت تخمین عمق بر حسب متر تفسیر شد. برای نمایش بصری نتایج، نقشه‌های عمق با استفاده از نقشه رنگی TURBO و با بازه ثابت صفر تا ۳۰ متر رنگ‌آمیزی شدند.

۲- تعیین ناحیه مورد بررسی

برای شناسایی محتوای نزدیک در مسیر حرکت، یک ناحیه مورد علاقه (ROI) در بخش مرکزی تصویر تعریف شد. این ناحیه ۸۰ درصد عرض تصویر، از ۱۰ تا ۹۰ درصد عرض، و ۷۰ درصد ارتفاع تصویر، از ۲۵ تا ۹۵ درصد ارتفاع، را پوشش می‌دهد. انتخاب این ناحیه باعث می‌شود تحلیل عمق بر بخش موردنظر از صحنه متمرکز شود.

[3] https://huggingface.co/datasets/vijpandaturtle/roadscapes-video

۳- محاسبه شاخص نزدیکی و تولید هشدار

برای هر فریم، صدک دهم مقادیر عمق معتبر درون ROI ، با نماد P10 ، محاسبه شد. این شاخص نماینده بخش پایین توزیع مقادیر عمق است و برای شناسایی محتوای نزدیک‌تر در ناحیه انتخاب‌شده استفاده می‌شود.

آستانه هشدار برابر با ۸ متر تعیین شد. اگر مقدار P10 در سه فریم متوالی کمتر از این آستانه باشد، هشدار فعال می‌شود. همچنین، هشدار زمانی غیرفعال می‌شود که مقدار P10 در سه فریم متوالی بالاتر از آستانه قرار گیرد. این سازوکار از تغییر مکرر وضعیت هشدار در اثر نوسانات کوتاه‌مدت تخمین عمق جلوگیری می‌کند. لازم به ذکر است این مقادیر از طریق اجزای چندین مرتبه آزمون بدست آمده است.

هنگام فعال بودن هشدار، عبارت «**WARNING! OBJECT TOO CLOSE**» روی فریم ویدئو نمایش داده می‌شود. علاوه بر ویدئوی خروجی، مقادیرP10 ، صدک بیست‌وپنجم(P25) ، حداقل عمق و وضعیت هشدار برای هر فریم در یک فایل CSV ذخیره شدند.

نتایج آزمایش

سامانه برای هر ۱۳۲۰ فریم ویدئو خروجی تولید کرد. نتایج فایل CSV نشان داد که:

- تعداد دفعات فعال‌شدن هشدار: ۸
- تعداد دفعات غیرفعال‌شدن هشدار: ۷
- تعداد فریم‌های دارای هشدار فعال: ۷۵۹ فریم، معادل حدود ۵۷٫۵ درصد کل فریم‌ها
- مجموع مدت تقریبی نمایش هشدار: ۲۵٫۳ ثانیه
- کمترین مقدار P10 در طول ویدئو: حدود ۳٫۰۸ متر
- بیشترین مقدار P10 در طول ویدئو: حدود ۹٫۳۳ متر
- میانگین P10 در طول ویدئو: حدود ۷٫۴۱ متر

هشدار برای نخستین بار در حدود ۰٫۰۷ ثانیه از ویدئوی برش‌خورده فعال شد و در انتهای ویدئو همچنان فعال بود. این زمان‌ها نسبت به ابتدای ویدئوی ۴۴ ثانیه‌ای محاسبه شده‌اند، نه ابتدای ویدئوی اصلی.

با وجود تولید موفق نقشه‌های عمق و ویدئوی هشدار، سامانه به نرخ فریم ورودی نرسید. زمان پردازش کل حدود ۲۶۹٫۵۷ ثانیه بود که معادل سرعت پردازش تقریبی ۴٫۹ فریم بر ثانیه است. بنابراین، پیاده‌سازی فعلی برای پردازش بلادرنگ ویدئوی ورودی با نرخ ۳۰ فریم بر ثانیه کافی نیست.

نمایش نمونه خروجی

در شکل زیر می‌توان یک فریم از ویدئوی رانندگی و نقشه عمق متناظر با آن را در کنار یکدیگر نمایش داد. در تصویر سمت چپ، وضعیت هشدار سامانه دیده می‌شود؛ تصویر سمت راست، نقشه عمق تخمینی و طیف رنگی مربوط به آن را نشان می‌دهد.



شکل ۱ .مقایسه فریم ورودی دارای هشدار نزدیکی با نقشه عمق تخمینی توسط Depth Anything V2 در زمان ۴۳ ثانیه از ویدئوی برش‌خورده.

محدودیت‌ها

این سامانه از آمار مقادیر عمق در یک ناحیه از تصویر استفاده می‌کند و تشخیص یا ردیابی اختصاصی اشیا را انجام نمی‌دهد. بنابراین، مقدار P10 ممکن است تحت تأثیر اشیا و بخش‌های مختلف صحنه قرار گیرد. همچنین، تفاوت میان دامنه آموزش مدل و ویدئوی ورودی می‌تواند بر دقت تخمین عمق تأثیر بگذارد.

آستانه ۸ متر یک مقدار آزمایشی برای تعیین وضعیت هشدار است و نباید آن را فاصله ایمن یا آستانه ایمنی تأییدشده برای خودرو در نظر گرفت. از آنجا که مقادیر تخمین‌زده‌شده با داده‌های مرجع عمق واقعی اعتبارسنجی نشده‌اند، فعال‌شدن هشدار لزوماً به معنای وجود خطر قطعی برخورد نیست. افزون بر این، سرعت پردازش فعلی پایین‌تر از نیاز پردازش بلادرنگ است.

نتیجه‌گیری و کارهای آینده

در این بخش، یک سامانه هشدار نزدیکی مبتنی بر Depth Anything V2 پیاده‌سازی شد که با تخمین عمق فریم‌های ویدئوی رانندگی، محاسبه صدک دهم عمق در ناحیه ROI و اعمال یک قاعده سه‌فریمی، وضعیت هشدار را تعیین می‌کند. سامانه توانست ویدئوی دارای هشدار، ویدئوی نمایش نقشه عمق و فایل CSV نتایج را تولید کند.

با این حال، فراوانی هشدارها و سرعت پردازش پایین‌تر از نرخ ورودی نشان می‌دهد که برای افزایش قابلیت اطمینان و کارایی، به بررسی‌های بیشتری نیاز است. در کارهای آینده می‌توان دقت تخمین عمق را با داده‌های مرجع ارزیابی کرد، آستانه هشدار را با توجه به سناریوهای مختلف رانندگی تنظیم نمود، از تشخیص و ردیابی اشیا برای تحلیل اختصاصی‌تر فاصله استفاده کرد و روش‌های بهینه‌سازی استنتاج را برای افزایش سرعت پردازش بررسی کرد.